

Análise de um Sistema de Filas M/M/2 com Buffer Finito e Taxa de Serviço Adaptativa

David Fabian Tavera Gutierrez

TP547

INATEL

Santa Rita do Sapucaí, MG, Brasil

Luis Enrique Cardozo Ramirez

TP547

INATEL

Santa Rita do Sapucaí, MG, Brasil

Abstract—O presente trabalho investiga o desempenho de um sistema de filas M/M/2 com capacidade de espera finita (buffer de tamanho J) e uma estratégia adaptativa para a taxa de serviço. O sistema opera com duas taxas de serviço distintas: uma taxa normal (μ_1) e uma taxa elevada (μ_2). A transição da taxa normal para a elevada ocorre quando o número total de clientes no sistema atinge ou excede um limiar predefinido m . Mediante simulação de eventos discretos implementada em Python, o sistema é analisado sob diferentes condições, incluindo variações na taxa de chegada (λ), no tamanho do buffer (J) e no limiar de ativação (m). Os resultados demonstram um claro compromisso (trade-off) entre as métricas de desempenho — tempo médio no sistema (W) e probabilidade de bloqueio (P_B) — e o custo operacional, quantificado como a fração de tempo em que o sistema opera com a taxa de serviço mais alta (U_{μ_2}). Apresentam-se estudos de caso em computação em nuvem e redes de telecomunicações para ilustrar a aplicabilidade do modelo. Conclui-se que o limiar m é um parâmetro de projeto crítico que permite ajustar o sistema para priorizar seja a qualidade de serviço, seja a eficiência no uso de recursos, uma observação fundamental para o projeto de sistemas dinâmicos e responsivos.

Index Terms—Teoria de filas, M/M/2, taxa de serviço adaptativa, simulação de eventos discretos.

I. INTRODUÇÃO

A teoria de filas é o ramo da matemática que se dedica ao estudo das linhas de espera. Desde seu surgimento no início do século XX, com o trabalho de A. K. Erlang sobre congestionamento telefônico, tornou-se uma ferramenta indispensável para a análise, o projeto e a otimização de sistemas em inúmeros campos. Os sistemas de filas são modelos matemáticos que representam processos onde “clientes” (que podem ser pessoas, pacotes de dados, peças em uma fábrica, etc.) chegam solicitando um “serviço” a “servidores” com capacidade limitada, o que pode gerar esperas [1].

Em muitos sistemas contemporâneos, nem a demanda nem as condições operacionais são estáticas. A capacidade de adaptar dinamicamente os recursos em resposta às flutuações da carga é crucial para a eficiência. Uma estratégia de controle eficaz é a adaptação da taxa de serviço, na qual a capacidade do sistema é ajustada em função do nível de congestionamento observado. Esta estratégia tem sido estudada em diversos contextos teóricos, frequentemente como um processo de decisão de Markov, onde o objetivo é encontrar uma política ótima

que equilibre os custos de espera com os custos de serviço. O modelo analisado neste trabalho, embora específico, captura a essência desse problema fundamental.

Este artigo apresenta uma análise detalhada de um sistema com dois servidores e uma taxa de serviço que varia em função de um limiar de ocupação. Utiliza-se a simulação como ferramenta de análise devido à complexidade do modelo e contextualiza-se sua relevância por meio de estudos de caso práticos, demonstrando como esses modelos teóricos informam o projeto de tecnologias do mundo real.

II. MODELO DO SISTEMA

Considera-se um sistema de filas que se ajusta à notação de Kendall M/M/2/K. Esta notação é descrita da seguinte forma:

- **M (Markoviano/Poisson):** O processo de chegada de clientes segue um processo de Poisson, o que implica que os tempos entre chegadas sucessivas são independentes e distribuídos exponencialmente com uma taxa média λ .
- **M (Markoviano/Exponencial):** Os tempos de serviço também são independentes e seguem uma distribuição exponencial. A taxa de serviço, μ , no entanto, é dependente do estado do sistema.
- **2:** Existem dois servidores idênticos (S_1 e S_2) operando em paralelo.
- **K:** A capacidade total do sistema é finita, com $K = J + 2$ clientes (um em cada servidor e J na fila de espera ou buffer). Um cliente que chega quando o sistema possui K clientes é rejeitado (bloqueado).

A. Estratégia de Serviço Adaptativa

A característica central do modelo é que a taxa de serviço não é constante. Seu valor depende do número total de clientes no sistema, n . A comutação é controlada por um limiar predefinido m , onde $2 \leq m \leq K$. A taxa de serviço de cada servidor, $\mu(n)$, é definida na Equação 1:

$$\mu(n) = \begin{cases} \mu_1, & \text{se } n < m \\ \mu_2, & \text{se } n \geq m \end{cases} \quad (1)$$

onde $\mu_2 > \mu_1$. Quando a taxa muda enquanto um cliente está sendo atendido, aplica-se o princípio de conservação de trabalho (*work-conserving*).




Fig. 1: Fluxograma ilustrativo da lógica da simulação de eventos discretos implementada.

III. METODOLOGIA DE ANÁLISE

Devido à complexidade do modelo, utiliza-se a **simulação de eventos discretos** (DES) [2]. Foi implementado um simulador em Python que acompanha a evolução do sistema evento por evento (chegadas e finalizações de serviço), coletando dados para estimar as métricas de desempenho.

A. Métricas de Desempenho

As principais métricas utilizadas para a avaliação são:

- **Tempo Médio no Sistema (W):** Medida chave da Qualidade de Serviço (QoS).
- **Probabilidade de Bloqueio (P_B):** Proporção de clientes rejeitados, crucial em sistemas com capacidade finita.

- **Utilização da Taxa Rápida (U_{μ_2}):** Fração do tempo em que o sistema opera à taxa μ_2 , representando o "custo operacional".

IV. RESULTADOS DA SIMULAÇÃO E DISCUSSÃO

Foi executada uma série de experimentos de simulação para analisar o comportamento do sistema.

A. Avaliação do Tamanho do Buffer

O experimento utilizou os seguintes parâmetros:

- **Fixos:** $\mu_1 = 10.0$; $\mu_2 = 20.0$; Número de chegadas $N = 100\,000$.
- **Variáveis:** $\lambda \in [10.0, 45.0]$; $J \in \{10, 20, 30\}$; $m \in \{5, 10, 15\}$.

A seguir, os resultados são apresentados na Fig. 2.




Fig. 2: Taxa de processamento (throughput) e probabilidade de bloqueio vs. taxa de chegada para diferentes tamanhos de buffer e limiares.

Os resultados indicam que um buffer maior ajuda a reduzir a probabilidade de bloqueio, mas também aumenta o tempo de permanência dos pacotes no sistema. Portanto, é necessário escolher um tamanho adequado para minimizar tanto o atraso quanto a probabilidade de bloqueio.

B. Avaliação de Desempenho

Este teste consiste em comparar o sistema adaptativo com duas configurações fixas. Os parâmetros são:

- **Fixos:** $\mu_1 = 10.0$; $\mu_2 = 20.0$; Número de chegadas $N = 100\,000$.
- **Variáveis:** $J = 10$; $m = 5$; e duas taxas de chegada: $\lambda = 15$ e $\lambda = 30$.

TABLE I: Comparação de métricas para $\lambda = 15$, $J = 10$, $m = 5$.

Parâmetros	Apenas $\mu_1 = 10$	Apenas $\mu_2 = 20$	Adaptativo $m = 5$
Tempo médio no sistema $E[t_q]$	0.2021	0.0582	0.1330
Nº clientes no sistema $E[q]$	3.0089	0.0582	1.9929
Tempo médio na fila $E[t_w]$	0.1280	0.0083	0.0423
Nº clientes na fila $E[w]$	1.5313	0.1249	0.6324
Prob. de rejeição P_B	0.76%	0.00%	0.01%

TABLE II: Comparação de métricas para $\lambda = 30$, $J = 10$, $m = 5$.

Parâmetros	Apenas $\mu_1 = 10$	Apenas $\mu_2 = 20$	Adaptativo $m = 5$
Tempo médio no sistema $E[t_q]$	0.5067	0.1042	0.1719
Nº clientes no sistema $E[q]$	10.1023	3.1002	5.0382
Tempo médio na fila $E[t_w]$	0.4067	0.0541	0.1071
Nº clientes na fila $E[w]$	8.1084	1.6089	3.1387
Prob. de rejeição P_B	33.58%	0.92%	1.84%

Conforme os resultados da Tabela I e da Tabela II, observa-se que tanto para o caso de carga baixa ($\lambda = 15$) quanto para o de carga alta ($\lambda = 30$), o sistema adaptativo permite obter um desempenho intermediário entre um sistema mais rápido e um mais lento. O fator que determina a proximidade com o sistema rápido é o limiar m ; um valor baixo de m faz com que a transição para a taxa elevada ocorra mais cedo do que um valor alto.

C. Análise do Consumo de Energia

Para quantificar o custo energético associado a cada política de adaptação da taxa de serviço, atribuímos a cada nível de velocidade (μ_1 , μ_2) um consumo de energia por unidade de tempo proporcional ao seu valor. Denotemos por e_1 e e_2 esses consumos específicos, de modo que o consumo médio total de energia por cliente satisfaz

$$E_{\text{energia}} = e_1 U_{\mu_1} + e_2 U_{\mu_2},$$

onde U_{μ_i} é a fração do tempo que o sistema opera à taxa μ_i .

Como métrica composta, definimos o *Tempo Total de Serviço* T_{tot} , que incorpora o efeito de possíveis bloqueios como

$$T_{\text{tot}} = \frac{W}{1 - P_B},$$

sendo W o tempo médio no sistema e P_B a probabilidade de rejeição.

Foram realizados experimentos de simulação para duas intensidades de carga, $\lambda = 10$ e $\lambda = 20$, variando o limiar m no intervalo de 2 a 10. As curvas de compromisso para cada intensidade são mostradas a seguir:

No caso de baixa carga ($\lambda = 10$, Fig. 3), a redução de m (ativação mais rápida de μ_2) melhora marginalmente o Tempo Total de Serviço, enquanto aumenta ligeiramente o consumo energético. Valores de $m < 6$ apresentam rendimentos decrescentes, sendo preferível manter m alto.

Por outro lado, com carga alta ($\lambda = 20$, Fig. 4), um limiar intermediário ($m \approx 5-7$) reduz significativamente T_{tot} com um incremento moderado no gasto energético. Limiares muito baixos ($m \leq 4$) não trazem vantagem adicional em T_{tot} , mas elevam o consumo, enquanto limiares altos ($m \geq 8$) penalizam ambos os aspectos.

Em conjunto, esses resultados confirmam que o limiar m é um parâmetro crítico para equilibrar qualidade de serviço e eficiência energética, cujo valor ótimo depende da intensidade da carga.

V. ESTUDOS DE CASO

A relevância deste modelo é ilustrada com as seguintes aplicações.




Fig. 3: Curva de compromisso entre consumo médio de energia e tempo total de serviço para $\mu_2 = 12.5$ e $\lambda = 10$. Cada ponto é rotulado com o valor de m .




Fig. 4: Curva de compromisso entre consumo médio de energia e tempo total de serviço para $\mu_2 = 12.5$ e $\lambda = 20$. Cada ponto é rotulado com o valor de m .

A. Gerenciamento de Energia em Centros de Dados

Em centros de dados, os processadores utilizam o Escalonamento Dinâmico de Tensão e Frequência (DVFS) para gerenciar a energia. Um servidor pode operar em um estado de baixo consumo (μ_1) ou de alto desempenho (μ_2). O limiar m corresponde ao número de requisições na fila de processamento. Se a fila cresce além de m , o sistema ativa o modo de alto desempenho para reduzir a latência [3]. O objetivo é equilibrar a latência das requisições com o custo da energia elétrica.

B. Controle de Congestionamento em Redes 5G

Em redes 5G, uma estação base (gNB) pode alocar mais ou menos blocos de recursos para um usuário, alterando sua taxa de transmissão de dados. Aqui, μ_1 representa uma taxa

de transmissão base e μ_2 , uma taxa aprimorada. O limiar m é o número de pacotes no buffer de transmissão do usuário. Se o buffer excede m , o escalonador da gNB pode alocar mais recursos para evitar a perda de pacotes e reduzir a latência [4].

VI. CONCLUSÃO E TRABALHOS FUTUROS

A capacidade de alternar entre duas taxas de serviço (μ_1 e μ_2) permite que o sistema se ajuste dinamicamente ao nível de congestionamento. Isso possibilita a manutenção de tempos de espera baixos quando a carga aumenta e, ao mesmo tempo, a operação de forma mais econômica quando a demanda é moderada.

O sistema permite otimizar seu gasto energético: utilizando o modo de baixa potência (μ_1) durante períodos de pouca atividade e o modo de alto desempenho (μ_2) apenas quando um determinado limiar é ultrapassado. Dessa forma, minimiza-se o consumo médio de energia sem sacrificar a qualidade de serviço.

A política adaptativa unifica as vantagens de ambos os cenários: flexibilidade para enfrentar picos de tráfego e economia de energia em condições normais. Selecionando adequadamente os parâmetros m e J , conforme a natureza da aplicação, obtém-se um equilíbrio ótimo entre tempo de resposta, taxa de rejeição e consumo energético, tornando este esquema uma solução atraente para diferentes sistemas.

Como trabalhos futuros, propõem-se três linhas de investigação:

- 1) **Modelos Não-Markovianos (M/G/2):** Para representar de maneira mais realista as cargas de trabalho.
- 2) **Mecanismo de Histerese:** Introduzir diferentes limites para aumentar e diminuir a taxa, evitando assim oscilações rápidas.
- 3) **Otimização Dinâmica:** Utilizar aprendizado por reforço para que o sistema aprenda o valor ótimo de m dinamicamente.

REFERENCES

- [1] D. Gross, J. F. Shortle, J. M. Thompson, and C. M. Harris, *Fundamentals of Queueing Theory*, 4th ed. Hoboken, NJ, USA: John Wiley & Sons, 2008.
- [2] A. M. Law, *Simulation Modeling and Analysis*, 5th ed. New York, NY, USA: McGraw-Hill Education, 2015.
- [3] A. Gandhi, M. Harchol-Balter, and R. Raghunathan, "Optimal Power Allocation in Server Farms," in *Proc. ACM SIGMETRICS Int. Conf. on Measurement and Modeling of Computer Systems (SIGMETRICS '10)*, New York, NY, USA, 2010, pp. 157–168.
- [4] S. Ryden and G. Tsiourvas, "Analysis of an M/M/c queue with queueing-time dependent service rates," in *Proc. 10th EAI Int. Conf. on Performance Evaluation Methodologies and Tools (VALUETOOLS '17)*, New York, NY, USA, 2017, pp. 253–258.